

**Akademia Górniczo-Hutnicza im. Stanisława Staszica  
Wydział Automatyki, Elektroniki Informatyki i Inżynierii  
Biomedycznej**



## **Automatyczna segmentacja nerek**

**Projekt realizowany w ramach przedmiotu Techniki Obrazowania  
Medycznego**

**Kuba Chrobociński, Adrian Bieliński, Agata Machałek  
Kraków, 22 czerwca 2020**

# 1 Cel projektu

Celem projektu jest automatyczna segmentacja obrazu nerek pozyskanego z tomografii komputerowej. Otrzymany obraz należy podzielić na trzy obszary: tło, nerkę oraz guz nowotworowy. Dane oraz fragmenty kodu do ładowania danych otrzymane zostały z repozytorium challenge'u KiTS19 (<https://github.com/neheller/kits19>).

## 2 Rozwój projektu

Pierwotne rozwiązanie problemu korzystało z modelu SVM. Jest on powszechnie stosowany w segmentacji obrazów medycznych i możliwe było znalezienie wielu artykułów naukowych opisujących jego wykorzystanie. Założono zaimplementowanie trzech głównych etapów: preprocessingu, treningu modelu SVM na zbiorze treningowym oraz walidacji na zbiorze testowym. Stosowana wtedy funkcja preprocessingu miała wszystkie funkcjonalności funkcji obecnie stosowanej, a także wyrównywała wymiarowość case'ów, co było wymagane przez SVM. Odbywało się to poprzez dodanie do case'ów o mniejszej liczbie slice'ów pustych slice'ów oznaczonych w całości jako 'tło', co nie wpływało na ostateczną dokładność modelu. Ostatecznie klasyfikacja polegała na klasyfikowaniu poszczególnych pikseli do określonej klasy - 'tło', 'nerka' lub 'nowotwór'. Niestety zaimplementowane rozwiązanie posiadało określoną wadę - klasyfikacja nie zależała od sąsiadujących pikseli. Dlatego zdecydowano się na użycie sieci neuronowej w architekturze U-net.

## 3 Zaimplementowane rozwiązanie

Pomysł na rozwiązanie problemu klasyfikacji nerek i guza z obrazu tomografii komputerowej zakłada zaimplementowanie trzech głównych etapów: preprocessingu, treningu modelu SVM na zbiorze treningowym oraz walidacji na zbiorze testowym.

1. Preprocessing - dla każdego przekroju kolejnych case'ów tworzymy maskę binarną za pomocą, której wytniemy część obrazu. Najpierw tworzymy kopię oryginalnego obrazu, przeprowadzamy adaptacyjne wyrównanie histogramu, przepuszczamy przez filtr medianowy, dokonujemy poprawy kontrastu poprzez funkcję gamma. Po tych procedurach dokonujemy pierwszej operacji wielokrotnego progowania metodą Otsu, wycinamy z oryginalnego obrazu obszar nas interesujący, następnie przeprowadzamy ponownie operację wyrównania histogramu oraz wielokrotnego progowania. Tak otrzymaną maskę poddajemy zamknięciu oraz usuwamy małe czarne punkty. Wyrównujemy histogram danych oryginalny, a następnie wycinamy interesujący nas obszar za pomocą otrzymanej maski.
2. Architektura modelu - użyta została konwolucyjna sieć neuronowa w architekturze U-net. Nazwa pochodzi od dwóch "ścieżek" występujących w sieci. Jedna, w której warstwy przeprowadzają Upsampling i druga, która przeprowadza Downsampling.

Narysowana sieć w tej architekturze przypomina właśnie kształtem literę "U". Zamieszczony został na repozytorium wykres zastosowanego modelu. Sieci w architekturze U-net są powszechnie stosowane w zagadnieniach związanych z segmentacją obrazów biomedycznych, co związane jest z genezą ich pochodzenia, a konkretnie zaprezentowane zostały one jako koncept w artykule Olaf'a Ronneberger'a, Philipp'a Fischer'a i Thomas'a Brox'a pod tytułem 'U-Net: Convolutional Networks for Biomedical Image Segmentation' z 2015 roku.

3. Ewaluacja - ewaluacja została wykonana za pomocą odległości Hausdorff'a na 50 przypadkach. Obliczone zostanie odchylenie standardowe oraz średnia. Wyświetlone zostaną również przykładowe obrazy wraz z prawdziwą maską oraz przewidywaną przez model maską.

## 4 Podział obowiązków

1. Kuba Chrobociński - implementacja modelu i trenowanie
2. Adrian Bieliński - preprocessing
3. Agata Machałek - walidacja

## 5 Zaimplementowane funkcje

- preprocessing(case\_nr, slice\_nr\_to\_print)
  - Parametry:
    - \* case\_nr - numer pacjenta.
    - \* slice\_nr\_to\_print - użytkownik może wyrysować obraz przed preprocess'ingiem, po oraz użytą maskę binarną.
  - Wyjścia:
    - \* result - obraz znormalizowany.


Na preprocessing składają się również dwie funkcje wewnętrzne:

- normalize(image)  
Funkcja normalizująca wczytane obrazy z zakresu (0, 255)Int do (0,1)Float.
  - \* Parametry:
    - image - obraz wejściowy.
  - \* Wyjścia:
    - result - obraz znormalizowany.
- slice\_pre(data\_slice) Funkcja, która wykonuje preprocessing (opisany szczegółowo w punkcie „Zaimplementowane rozwiązanie”) na pojedynczym slice.
  - \* Parametry:


- data\_slice - wejściowy obraz (pojedynczy slice)
- \* Wyjścia:
  - data\_preprocessed - slice poddany preprocessingowi.
  - data\_mask - maska binarna stworzona w celu zmniejszenia obszaru zainteresowania.
- get\_data(case\_nr)
  - Parametry:
    - \* case\_nr - numer pacjenta do wczytania
  - Funkcje wewnętrzne:
    - \* get\_case(case\_nr) - wczytuje dane obrazowe
    - \* get\_segment(case\_nr) - wczytuje segmentację danego pacjenta
  - Wyjścia:
    - \* X - macierz z danymi obrazowymi
    - \* Y - macierz z segmentacją
- prep\_data(case\_nr)
  - Parametry:
    - \* case\_nr - numer pacjenta do wczytania
  - Wyjścia:
    - \* data - dane z odpowiednio dopasowanymi rozmiarami
    - \* mask - maska z odpowiednio dopasowanymi rozmiarami
- unet(pretrained\_weights, input\_size)
  - Parametr:
    - \* pretrained\_weights - wcześniej wytrenowane wagi
    - \* input\_size - rozmiar danych wejściowych
  - Wyjścia:
    - \* model - instancja modelu U-net

## 6 Wyniki


Otrzymana przez nas sieć dawała radę z rozpoznawaniem nerek oraz tła, niestety większy problem wystąpił przy próbie rozpoznania nowotworu co jest kluczową częścią tego projektu. Poniżej przykładowe obrazu pacjenta numer 102. Widoczne na nim są dobrze nerki oraz tło. Niestety zdarzają się również slice'y, dla których występuje 'mgiełka'.



*Rysunek 1. Przykładowy wynik o wysokiej poprawności*



*Rysunek 2. Przykładowy wynik o średniej poprawności*



*Rysunek 3. Przykładowy wynik z "mgiełką"*

## **7 Dyskusja**

## **8 Obszary do ulepszenia**

1. Preprocessing - zauważone zostały pewne błędy przy preprocessing'u polegające na wycięciu jednej z nerek w czasie obróbki dla niektórych z pacjentów. Należałoby odpowiednio przyjrzeć się tym przypadkom i dobrać inny zestaw filtrów lub zmienić parametry obecnie używanych. Należy dopracować również procedurę obróbki wstępnej aby guzy nowotworowe były bardziej widoczne.
2. Model - prawdopodobnym jest zmniejszenie rozmiarów sieci bez spadku w wydajności co by się przyczyniło do zmniejszenia obciążenia sprzętowego. Należałoby przetestować taką możliwość. Przyjrzeć się również należy architekturze sieci i należy podjąć próbę lepszego dostrojenia parametrów.
3. Walidacja - użycie większej ilości metryk.